

---

## TP 2.2 - GENERADORES DE NÚMEROS PSEUDOALEATORIOS DE DISTINTAS DISTRIBUCIONES DE PROBABILIDAD

---

**Juan Pablo Jaca**

Legajo: 50311

Comisión: 402

Universidad Tecnológica Nacional - FRRO

Zeballos 1341, S2000, Argentina

juampijaca@gmail.com

**Nahuel Berli**

Legajo: 50310

Comisión: 402

Universidad Tecnológica Nacional - FRRO

Zeballos 1341, S2000, Argentina

nahuel.berli@gmail.com

**Juan Cruz Mondino**

Legajo: 51922

Comisión: 402

Universidad Tecnológica Nacional - FRRO

Zeballos 1341, S2000, Argentina

juancm.2000@hotmail.com

**Gustavo Giampietro**

Legajo: 50671

Comisión: 402

Universidad Tecnológica Nacional - FRRO

Zeballos 1341, S2000, Argentina

gustgiam2001@gmail.com

**Mateo Seffino**

Legajo: 50939

Comisión: 402

Universidad Tecnológica Nacional - FRRO

Zeballos 1341, S2000, Argentina

seffinomateo@gmail.com

**Alexis Mateo**

Legajo: 51191

Comisión: 402

Universidad Tecnológica Nacional - FRRO

Zeballos 1341, S2000, Argentina

alexisjoelmateo@gmail.com

21 de mayo de 2025

### ABSTRACT

El siguiente documento tiene por objetivo presentar el trabajo de investigación realizado para finalizar con nuestro estudio sobre los números pseudoaleatorios, del cual van a depender nuestros próximos experimentos.

**Keywords** Simulación · generadores pseudoaleatorios · distribuciones de probabilidad

## Índice

|                                                                |           |
|----------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                         | <b>3</b>  |
| <b>2. Método de la Transformación Inversa</b>                  | <b>3</b>  |
| <b>3. Método de Rechazo</b>                                    | <b>4</b>  |
| <b>4. Distribuciones de Probabilidad</b>                       | <b>5</b>  |
| 4.1. Distribuciones Continuas . . . . .                        | 5         |
| 4.1.1. Distribución Uniforme . . . . .                         | 5         |
| 4.1.2. Distribución Exponencial . . . . .                      | 12        |
| 4.1.3. Distribución Gamma . . . . .                            | 13        |
| 4.1.4. Distribución Normal . . . . .                           | 14        |
| 4.2. Distribuciones Discretas . . . . .                        | 22        |
| 4.2.1. Distribución Pascal (Binomial Negativa) . . . . .       | 23        |
| 4.2.2. Distribución Binomial . . . . .                         | 24        |
| 4.2.3. Distribución Hipergeométrica . . . . .                  | 26        |
| 4.2.4. Distribución Poisson . . . . .                          | 27        |
| 4.2.5. Distribución Empírica Discreta . . . . .                | 29        |
| <b>5. Metodología de Trabajo</b>                               | <b>31</b> |
| 5.1. Implementación de los métodos de generación . . . . .     | 31        |
| 5.2. Distribuciones implementadas . . . . .                    | 31        |
| 5.3. Visualización mediante histogramas comparativos . . . . . | 32        |
| 5.4. Tests estadísticos . . . . .                              | 32        |
| 5.5. Estructura general del código . . . . .                   | 33        |
| 5.6. Ejecución y resultados . . . . .                          | 33        |
| 5.7. Análisis de eficiencia . . . . .                          | 33        |
| 5.8. Bibliotecas utilizadas . . . . .                          | 34        |
| <b>6. Conclusiones</b>                                         | <b>34</b> |
| <b>Referencias</b>                                             | <b>34</b> |

## 1. Introducción

Las distribuciones de probabilidad constituyen uno de los pilares fundamentales en la teoría estadística y el análisis de fenómenos aleatorios. Estas distribuciones proporcionan modelos matemáticos que describen el comportamiento estocástico de variables aleatorias, permitiendo cuantificar la incertidumbre inherente a diversos procesos naturales, sociales, económicos y tecnológicos. En esencia, una distribución de probabilidad asigna a cada posible resultado de un experimento aleatorio una probabilidad específica, creando así un marco formal para analizar y predecir comportamientos bajo condiciones de incertidumbre. La relevancia de estas distribuciones trasciende el ámbito puramente teórico, manifestándose en aplicaciones concretas como el diseño de experimentos científicos, la evaluación de riesgos financieros, el control de calidad industrial, y la simulación computacional de sistemas complejos.

El estudio de las distribuciones de probabilidad abarca tanto aspectos teóricos como prácticos. Desde una perspectiva teórica, involucra la caracterización de sus propiedades matemáticas, incluyendo funciones de densidad, funciones de distribución acumulativa, momentos estadísticos y transformaciones. En el ámbito práctico, se centra en la selección del modelo probabilístico más adecuado para representar un fenómeno específico, la estimación de parámetros a partir de datos empíricos, y la validación de hipótesis mediante pruebas estadísticas. Las distribuciones se clasifican fundamentalmente en dos categorías: discretas y continuas. Las distribuciones discretas modelan variables que pueden adoptar únicamente valores aislados, generalmente enteros, mientras que las distribuciones continuas representan variables que pueden tomar cualquier valor dentro de un intervalo real.

El documento que se desarrolla a continuación profundiza en diversas distribuciones de probabilidad continuas y discretas, cada una de las cuales surge de contextos probabilísticos específicos y ofrece soluciones a diferentes problemas de modelado estadístico. La comprensión de sus fundamentos teóricos, propiedades características y métodos de simulación resulta esencial para su correcta aplicación en el análisis de datos y la construcción de modelos estocásticos. A través de un enfoque metodológico que combina precisión matemática con orientación práctica, se presentan las bases conceptuales de estas distribuciones, sus parámetros definitorios, y las técnicas para generar valores aleatorios que se ajusten a ellas mediante métodos computacionales.

## 2. Método de la Transformación Inversa

Si deseamos generar los valores  $x_i$  de las variables aleatorias a partir de cierta estadística de población cuya función de densidad esté dada por  $f(x)$ , debemos en primer lugar obtener la función de distribución acumulativa  $F(x)$ , tal y como se puede observar en la Figura 1. Puesto que  $F(x)$  se define sobre el rango de 0 a 1, podemos generar números aleatorios distribuidos uniformemente y además hacer  $F(x) = r$ .




Figura 1: Función de distribución acumulativa.

Resulta claro, entonces, cómo queda  $x$  determinada unívocamente por  $r = F(x)$ . Sigue, por lo tanto, que para cualquier valor particular de  $r$ , que generemos, por ejemplo  $r_0$ , siempre es posible encontrar el valor de  $x$ ; en este caso  $x_0$ , que corresponde a  $r_0$  debido a la función inversa de  $F$ , si es conocida. Esto es,

$$x_0 = F^{-1}(r_0) \quad (2.1)$$

donde  $F^{-1}(x)$  es la transformación inversa (o mapeo) de  $r$  sobre el intervalo unitario en el dominio de  $x$ . Si generamos números aleatorios uniformes correspondientes a una  $F(x)$  dada, podemos resumir, matemáticamente, este método como sigue:

$$r = F(x) = \int_{-\infty}^x f(t) dt \quad (2.2)$$

entonces

$$P(X \leq x) = F(x) = P[r \leq F(x)] = P[F^{-1}(r) \leq x] \quad (2.3)$$

y consecuentemente  $F^{-1}(r)$  es una variable que tiene a  $f(x)$  como función de densidad de probabilidad. Este criterio equivale a resolver la ecuación (2.3) en  $x$ , en términos de  $r$ .

### 3. Método de Rechazo

Si  $f(x)$  es una función acotada y  $x$  tiene además un rango finito, como  $a \leq x \leq b$ , entonces se puede utilizar la técnica de rechazos para generar los valores de variables aleatorias. La aplicación de esta técnica requiere que se proceda de acuerdo con las siguientes etapas:

1. Normalizar el rango de  $f$  mediante un factor de escala  $c$  tal que

$$c \cdot f(x) \leq 1 \quad a \leq x \leq b \quad (3.1)$$

2. Definir a  $x$  como una función lineal de  $r$ , o sea

$$x = a + (b - a) r \quad (3.2)$$

3. Generar parejas de números aleatorios  $(r_1, r_2)$ .
4. Siempre que se encuentre una pareja de números aleatorios que satisfagan la relación

$$r_2 \leq c \cdot f[a + (b - a)r_1]. \quad (3.3)$$

dicho par será aceptado y se utilizará a  $x = a + (b - a)r_1$  como el valor generado de la variable aleatoria.

La teoría sobre la que se apoya este método se basa en el hecho ya conocido relativo a la probabilidad de que  $r$  sea menor o igual a  $c \cdot f(x)$  es

$$P[r \leq c \cdot f(x)] = c \cdot f(x) \quad (3.4)$$

En consecuencia, si  $x$  se elige al azar dentro del rango  $(a, b)$  de acuerdo con la ecuación (3.2) y en el caso de que  $r > c \cdot f(x)$  se rechaza, la función de densidad de probabilidad de los valores de  $x$  aceptados deberá ser igual a  $f(x)$ . Tocher ha demostrado que la esperanza matemática del número de intentos que se realizan, antes de encontrar una pareja exitosa, es igual a  $1/c$ . Esto implica que para ciertas funciones de densidad de probabilidad este método puede resultar sumamente ineficaz.

## 4. Distribuciones de Probabilidad

### 4.1. Distribuciones Continuas

Una distribución de probabilidad continua es la distribución donde la variable aleatoria que puede tomar cualquiera de los infinitos valores existentes dentro de un intervalo. En el caso de variable continua, la distribución de probabilidad es la integral de la función de densidad, por lo que tenemos entonces que:

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt \quad (4.1)$$

A diferencia de las variables discretas, en las variables continuas la probabilidad de que la variable tome un valor exacto es cero, es decir,  $P(X = x) = 0$  para cualquier valor real  $x$ . Sin embargo, sí es posible calcular la probabilidad de que la variable se encuentre dentro de un cierto intervalo.

Entre las distribuciones de probabilidad continuas más conocidas que se utilizan en el modelado estadístico se incluyen:

- Distribución Uniforme
- Distribución Exponencial
- Distribución Gamma
- Distribución Normal

#### 4.1.1. Distribución Uniforme

Quizá la función de densidad de probabilidad mas simple es aquella que se caracteriza por ser constante, en el intervalo  $(a, b)$  y cero fuera de él. Esta función de densidad define la distribución conocida como uniforme o rectangular. La **distribución uniforme** surge cuando se estudian las características de los errores por redondeo al registrar un conjunto de medidas sujetas a cierto nivel de precisión. Por ejemplo, si se registran medidas de peso con una aproximación determinada en gramos, puede suponerse que la diferencia en gramos entre el peso real y el peso registrado corresponde a un cierto número entre  $-0.5$  y  $+0.5$ , y que el error se encuentra distribuido uniformemente en este intervalo. El valor mas sobresaliente que puede tener la distribución uniforme respecto a las técnicas de simulación radica en su simplicidad y en el hecho de que tal distribución se puede emplear para simular variables aleatorias a partir de casi cualquier tipo de distribución de probabilidad.

Matematicamente, la función de densidad uniforme se define como sigue:

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{fuera del intervalo } (a, b) \end{cases} \quad (4.2)$$

En esta expresión,  $X$  es una variable aleatoria definida en el intervalo  $(a, b)$ .

La gráfica de la distribución uniforme queda ilustrada en la Figura 2.




Figura 2: Gráfica de la Distribución Uniforme.

La función de la distribución acumulativa  $F(x)$ , para una variable aleatoria  $X$  uniformemente distribuida, se puede representar por

$$F(x) = \int_a^x \frac{1}{b-a} dt = \frac{x-a}{b-a} \quad 0 \leq F(x) \leq 1 \quad (4.3)$$

El valor esperado y la varianza de una variable aleatoria uniformemente distribuida están dados por las siguientes expresiones

$$EX = \int_a^b \frac{1}{b-a} x dx = \frac{b+a}{2} \quad (4.4)$$

$$VX = \int_a^b \frac{(x-EX)^2}{b-a} dx = \frac{(b-a)^2}{12} \quad (4.5)$$

Al efectuar aplicaciones de esta función, los parámetros de la función de densidad uniforme definida por partes más arriba, es decir, los valores numéricos de  $a$  y de  $b$ , no necesariamente deben ser conocidos en forma directa. En casos típicos, aunque esto no sucede en todas las distribuciones uniformes, solamente conocemos la media y la varianza de la estadística que se va a generar.

En estos casos, los valores de los parámetros se deben derivar al resolver el sistema que consta de las ecuaciones del valor esperado y la varianza, para  $a$  y para  $b$ , pues se supone que  $EX$  y  $VX$  son conocidos. Este procedimiento, semejante a una técnica de estimación conocida en la literatura estadística como método de momentos, proporciona las siguientes expresiones:

$$a = EX - \sqrt{3VX} \quad (4.6)$$

$$b = 2EX - a \quad (4.7)$$

Para simular una distribución uniforme sobre cierto intervalo conocido  $(a, b)$  deberemos, en primer lugar, obtener la transformación inversa para la ecuación (4.3), de acuerdo con la ecuación (2.1).

$$x = a + (b-a)r \quad 0 \leq r \leq 1 \quad (4.8)$$

Enseguida generamos un conjunto de números aleatorios correspondiente al rango de las probabilidades acumulativas, es decir, los valores de variables aleatorias uniformes definidas sobre el rango 0 a 1. Cada número aleatorio  $r$  determina, de manera única, un valor de la variable aleatoria  $x$  uniformemente distribuida.

Para aclarar estas afirmaciones es probable que lo mejor sea presentar una explicación gráfica.




Figura 3: Asociación de cada valor generado de  $r$  con un único valor de  $x$ .

La Figura 3 nos ilustra como cada valor generado de  $r$  está asociado con uno y sólo un valor de  $x$ . Por ejemplo, el valor específico de la función de distribución acumulativa en  $r_0$  determina el valor de  $x$  en  $x_0$ . Obviamente, este procedimiento se puede repetir tantas veces como se desee y en cada repetición se generara un nuevo valor de  $x$ .

A continuación, compartimos el código desarrollado en Python sobre la generación de números pseudoaleatorios con una Distribución Uniforme, el Método de la Transformación Inversa, el Método de Rechazo, el testeo de la generación de los valores y la generación de gráficas que representen dichos valores generados por los métodos:

### Distribución Uniforme original

---

```

1 import numpy as np
2
3 ## Distribucion Uniforme
4
5 orig_a, orig_b = 0, 1
6 num_muestras = 1000
7 datos_dist_unif_original = np.random.uniform(orig_a, orig_b, num_muestras)
8
9 print("\n--- Estadísticas de la Distribucion Uniforme ---")
10 print(
11     f" Uniforme U({orig_a}, {orig_b}): Media = {np.mean(datos_dist_unif_original):.3f} (Teorica: {(orig_a + orig_b)/2}), "
12     f"Varianza = {np.var(datos_dist_unif_original):.3f} (Teorica: {(orig_b - orig_a)**2 / 12})"
13 )

```

---

Código 1: Implementación de la generación de 1000 números pseudoaleatorios entre 0 y 1 mediante el método *uniform* del módulo *random* de la librería *NumPy*.

### Método de la Transformación Inversa

---

```

1 import numpy as np
2
3
4 def transformada_inversa_uniforme(array, limiteInf, limiteSup):
5     return limiteInf + (limiteSup - limiteInf) * array
6
7
8 inv_a, inv_b = 0, 10
9 numeros_aleatorios = np.random.rand(num_muestras)
10 datos_inversa = transformada_inversa_uniforme(numeros_aleatorios, inv_a, inv_b)
11
12 print("\n--- Estadísticas de la Transformada Inversa de la Distribucion Uniforme ---")
13

```

---

---

```

14 print(
15     f"    Uniforme U({inv_a}, {inv_b}): Media = {np.mean(datos_inversa):.3f} (
16         Teorica: {(inv_a + inv_b)/2}), "
17     f"Varianza = {np.var(datos_inversa):.3f} (Teorica: {(inv_b - inv_a)**2 / 12})"
18 )

```

---

Código 2: Implementación del Método de Transformación Inversa para generar muestras de una Distribución Uniforme  $U(0, 10)$  a partir de números pseudoaleatorios.

### Método de Rechazo

---

```

1 import numpy as np
2
3 # Suponemos que deseamos generar muestras de U(2, 5) usando el metodo de rechazo
4 rech_a, rech_b = 2, 5 # Intervalo objetivo de la distribucion uniforme
5 cota_superior = (
6     1.0 # Cota superior para la funcion de densidad (PDF constante en uniforme)
7 )
8
9 muestras_rechazo = []
10 while len(muestras_rechazo) < num_muestras:
11     x_candidato = np.random.uniform(rech_a, rech_b)
12     y_candidato = np.random.uniform(0, cota_superior)
13
14     if y_candidato <= 1 / (rech_b - rech_a):
15         muestras_rechazo.append(x_candidato)
16
17 muestras_rechazo = np.array(muestras_rechazo)
18
19 print("\n--- Estadisticas del Metodo de Rechazo ---")
20 print(
21     f"    Uniforme U({rech_a}, {rech_b}): Media = {np.mean(muestras_rechazo):.3f} (
22         Teorica: {(rech_a + rech_b)/2}), "
23     f"Varianza = {np.var(muestras_rechazo):.3f} (Teorica: {(rech_b - rech_a)**2 /
24         12})"
25 )

```

---

Código 3: Implementación del Método de Rechazo para generar muestras de una Distribución Uniforme  $U(2, 5)$  utilizando una cota superior para la función de densidad.

### Testeo estadístico de la generación de valores

---

```

1 from scipy.stats import kstest
2
3 ## Testeo
4
5 # Test de Kolmogorov-Smirnov para la distribucion uniforme original
6 print("\n--- Testeo de la Distribucion Uniforme ---")
7
8 ks_stat_orig, p_val_orig = kstest(
9     datos_dist_unif_original, "uniform", args=(orig_a, orig_b - orig_a)
10 )
11 print(
12     f"    KS Test U({orig_a}, {orig_b}): Estadistico = {ks_stat_orig:.4f}, p-valor =
13         {p_val_orig:.4f}"
14 )
15
16 if p_val_orig > 0.05:
17     print(
18         "    La muestra original proviene de una distribucion uniforme (Kolmogorov-
19             Smirnov no rechaza la Hipotesis Nula (H0))."
20     )

```

---



```

19 else:
20     print(
21         "    La muestra original NO parece provenir de una distribucion uniforme (
                Kolmogorov-Smirnov rechaza la Hipotesis Nula (H0))."
22     )
23
24 # Test de Kolmogorov-Smirnov para la transformada inversa
25 print("\n--- Testeo de la Transformada Inversa de la Distribucion Uniforme ---")
26
27 ks_stat_inv, p_val_inv = kstest(datos_inversa, "uniform", args=(inv_a, inv_b -
                inv_a))
28 print(
29     f"    KS Test U({inv_a}, {inv_b}): Estadistico = {ks_stat_inv:.4f}, p-valor = {
                p_val_inv:.4f}"
30 )
31
32 if p_val_inv > 0.05:
33     print(
34         "    La muestra generada por transformacion inversa proviene de una
                distribucion uniforme (Kolmogorov-Smirnov no rechaza la Hipotesis Nula
                (H0))."
35     )
36 else:
37     print(
38         "    La muestra generada por transformacion inversa NO parece provenir de
                una distribucion uniforme (Kolmogorov-Smirnov rechaza la Hipotesis Nula
                (H0))."
39     )
40
41 # Test de Kolmogorov-Smirnov para el metodo de rechazo
42 print("\n--- Testeo del Metodo de Rechazo ---")
43
44 ks_stat_rej, p_val_rej = kstest(
45     muestras_rechazo, "uniform", args=(rech_a, rech_b - rech_a)
46 )
47 print(
48     f"    KS Test U({rech_a}, {rech_b}): Estadistico = {ks_stat_rej:.4f}, p-valor =
                {p_val_rej:.4f}"
49 )
50
51 if p_val_rej > 0.05:
52     print(
53         "    La muestra generada por el metodo de rechazo proviene de una
                distribucion uniforme (Kolmogorov-Smirnov no rechaza la Hipotesis Nula
                (H0))."
54     )
55 else:
56     print(
57         "    La muestra generada por el metodo de rechazo NO parece uniforme (
                Kolmogorov-Smirnov rechaza la Hipotesis Nula (H0))."
58     )

```

---

Código 4: Tests de Kolmogorov-Smirnov para validar que las muestras generadas por los distintos métodos siguen una distribución uniforme con los parámetros especificados.

## Generación de Gráficas

---

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.stats import uniform
4
5
6 plt.figure(figsize=(15, 6))
7
8 # Grafica de la distribucion uniforme original
9 plt.subplot(1, 3, 1)
10 plt.hist(
11     datos_dist_unif_original,
12     bins=30,
13     density=True,
14     alpha=0.7,
15     color="b",
16     edgecolor="black",
17     label="Muestras",
18 )
19 x_pdf_original = np.linspace(orig_a - 0.2, orig_b + 0.2, 100)
20 plt.plot(
21     x_pdf_original,
22     uniform.pdf(x_pdf_original, loc=orig_a, scale=orig_b - orig_a),
23     "r-",
24     linewidth=2,
25     label="PDF Teorica",
26 )
27 plt.title(f"Distribucion Uniforme U({orig_a}, {orig_b})")
28 plt.xlabel("Valor")
29 plt.ylabel("Densidad")
30 plt.xlim(orig_a - 0.2, orig_b + 0.2)
31 plt.legend()
32
33 # Grafica de la transformada inversa
34 plt.subplot(1, 3, 2)
35 plt.hist(
36     datos_inversa,
37     bins=30,
38     density=True,
39     alpha=0.7,
40     color="skyblue",
41     edgecolor="black",
42     label="Muestras",
43 )
44 x_pdf_inversa = np.linspace(inv_a - 1, inv_b + 1, 1000)
45 plt.plot(
46     x_pdf_inversa,
47     uniform.pdf(x_pdf_inversa, loc=inv_a, scale=inv_b - inv_a),
48     "r-",
49     label="PDF Teorica",
50 )
51 plt.title(
52     f"Distribucion Uniforme U({inv_a}, {inv_b}) \n(Metodo Transformacion Inversa)"
53 )
54 plt.xlabel("Valor")
55 plt.ylabel("Densidad")
56 plt.xlim(inv_a - 1, inv_b + 1)
57 plt.legend()
58
59 # Grafica del metodo de rechazo
60 plt.subplot(1, 3, 3)
61 plt.hist(
62     muestras_rechazo,
```

```

63     bins=30,
64     density=True,
65     alpha=0.7,
66     color="skyblue",
67     edgecolor="black",
68     label="Muestras",
69 )
70 x_pdf_rechazo = np.linspace(rech_a - 1, rech_b + 1, 1000)
71 plt.plot(
72     x_pdf_rechazo,
73     uniform.pdf(x_pdf_rechazo, loc=rech_a, scale=rech_b - rech_a),
74     "r-",
75     label="PDF Teorica",
76 )
77 plt.title(f"Distribucion Uniforme U({rech_a}, {rech_b}) \n(Metodo de Rechazo)")
78 plt.xlabel("Valor")
79 plt.ylabel("Densidad")
80 plt.xlim(rech_a - 1, rech_b + 1)
81 plt.legend()
82
83 plt.tight_layout()
84 plt.savefig("distribuciones_uniformes.png")
85 plt.show()

```

Código 5: Código para la generación de gráficas comparativas mostrando histogramas de las muestras y las funciones de densidad teóricas para cada método implementado.

## Gráficas generadas

Estas son las gráficas generadas por el código anterior:




Figura 4: Comparación de distribuciones uniformes generadas por diferentes métodos.

En la Figura 4, la gráfica de la izquierda representa una distribución  $U(0, 1)$  generada directamente con NumPy. Por otro lado, la del centro es una distribución  $U(0, 10)$  generada mediante el método de la transformación inversa. Por último, la gráfica de la derecha es una distribución  $U(2, 5)$  generada mediante el método de rechazo. Es importante destacar que cada gráfica muestra el histograma de las muestras generadas (en azul/celeste) y la función de densidad teórica (en rojo).

### 4.1.2. Distribución Exponencial

Durante nuestra experiencia diaria, observamos como transcurren los intervalos de tiempo definidos entre las ocurrencias de los eventos aleatorios distintos, y sobre la base de un plan de tiempos completamente independientes, recibimos información sobre numerosos eventos que ocurren en nuestro alrededor. Bastaría con citar los nacimientos, de funciones, accidentes, o conflictos mundiales, para mencionar sólo algunos. Si es muy pequeña la probabilidad de que ocurra un evento en un intervalo corto, y si la ocurrencia de tal evento es, estadísticamente independiente respecto a la ocurrencia de otros eventos, entonces el intervalo de tiempo entre ocurrencias de eventos de este tipo estará distribuido en forma exponencial. El hecho de que en el mundo real un proceso estocástico proporcione o no efectivamente valores de variables aleatorias de tipo exponencial, constituye una cuestión empírica cuya confirmación depende del grado en que satisfagan las suposiciones que sirven de base a la distribución exponencial. Específicamente, para los valores de variables aleatorias de tipo exponencial se deben satisfacer las siguientes suposiciones:

1. La probabilidad de que ocurra un evento en el intervalo  $[t, (t + \Delta t)]$  es  $\alpha \Delta t$
2.  $\alpha$  es una constante que no depende de  $t$  o de algún otro factor.
3. La probabilidad de que durante el intervalo  $[t, (t + \Delta t)]$  ocurra más de un evento, tiende a 0 a medida que  $\Delta t \rightarrow 0$  y su orden de magnitud deberá ser menor que el de  $\alpha \Delta t$

Se dice que una variable aleatoria  $X$  tiene una distribución exponencial, si se puede definir a su función de densidad como:

$$f(x) = \alpha e^{-\alpha x} \quad (4.9)$$

con  $\alpha > 0$  y  $x \geq 0$

La función de distribución acumulativa de  $X$  está dada por:

$$F(x) = \int_0^x \alpha e^{-\alpha t} dt = 1 - e^{-\alpha x} \quad (4.10)$$

y la media junto con la varianza de  $X$  se pueden expresar como

$$EX = \int_0^{\infty} x \alpha e^{-\alpha x} dx = \frac{1}{\alpha} \quad (4.11)$$

$$VX = \int_0^{\infty} (x - \frac{1}{\alpha})^2 \alpha e^{-\alpha x} dx = \frac{1}{\alpha^2} = (EX)^2 \quad (4.12)$$

Como la distribución exponencial solamente tiene un parámetro  $\alpha$ , es posible expresarlo como:

$$\alpha = \frac{1}{EX} \quad (4.13)$$

Existen muchas maneras para lograr la generación de valores de variables aleatorias exponenciales. Puesto que  $F(x)$  existe explícitamente, la técnica de la transformación inversa permite desarrollar métodos directos para dicha generación. Debido a la simetría que existe entre la distribución uniforme que sigue la intercambiabilidad de  $F(x)$  y  $1 - F(x)$ . Por lo tanto:

$$r = e^{-\alpha x} \quad (4.14)$$

y consecuentemente

$$x = -\frac{1}{\alpha} \log r = -EX \log r \quad (4.15)$$

Por consiguiente, para cada valor del número pseudoaleatorio  $r$  se determina un único valor para  $x$ . Los valores de  $x$  toman tan sólo magnitudes no negativas debido a que  $\log r \leq 0$  para  $0 \leq r \leq 1$ , y además se ajustan a la función de densidad exponencial con un valor esperado  $EX$ . Es conveniente notar, que pese a que esta técnica parece en principio muy simple, es preciso recordar que en una computadora digital el cálculo del logaritmo natural involucra una expansión en serie de potencias para cada valor de variable aleatoria uniforme que se deba generar.

A continuación, compartimos la gráfica generada durante el testeo de la generación de números pseudoaleatorios con una Distribución Exponencial:




Figura 5: Comparación de distribuciones exponenciales con parámetro  $\lambda = 2.0$  generadas mediante diferentes métodos.

En la Figura 5, el histograma verde muestra muestras obtenidas a través del método de la transformación inversa, mientras que el histograma azul corresponde al método de rechazo. La línea sólida negra representa la función de densidad teórica  $f(x) = \lambda e^{-\lambda x}$ . Ambos métodos producen distribuciones que se ajustan aproximadamente a la curva teórica.

#### 4.1.3. Distribución Gamma

Si un determinado proceso consiste de  $k$  eventos sucesivos y si el total del tiempo transcurrido para dicho proceso se puede considerar igual a la suma de  $k$  valores independientes de la variable aleatoria con distribución exponencial, cada uno de los cuales tiene un parámetro definido  $\alpha$ , la distribución de esta suma coincidirá con una distribución gamma con parámetros  $\alpha$  y  $k$ . La suma de los  $k$  (donde  $k$  es un entero positivo) valores de variable aleatoria con distribución exponencial con un mismo parámetro  $\alpha$ , también recibe el nombre de distribución de Erlang. Desde un punto de vista matemático la distribución de Erlang no es otra cosa que la convolución de  $k$  distribuciones exponenciales, o sea la distribución de la suma de  $k$  variables exponenciales. Aun más, si  $k$  se adecúa a la distribución binomial negativa o a la distribución geométrica, entonces la suma de  $k$  valores de variable aleatoria, con la misma  $\alpha$ , adoptará la forma de una distribución gamma. La forma más general de una distribución gamma se obtiene al considerar a  $k$  con valores positivos pero sin que estén restringidos a ser enteros. Casi siempre resulta posible ajustar alguna de las formas de la distribución gamma a un buen número de distribuciones de datos estadísticos sesgados en forma positiva.

La función gamma está descrita mediante la siguiente función de densidad:

$$f(x) = \frac{\alpha^k x^{k-1} e^{-\alpha x}}{(k-1)!} \quad (4.16)$$

donde  $\alpha > 0$ ,  $k > 0$  y  $x$  se considera no negativo. Pese a que no existe una forma explícita para describir la función acumulativa de la distribución gamma, Pearson ha logrado presentar, en forma tabular, los valores de la llamada función gamma incompleta. respecto a la media y a la varianza de esta distribución, sus correspondientes expresiones están formulada como sigue:

$$EX = \frac{k}{\alpha} \quad (4.17)$$

$$VX = \frac{k}{\alpha^2} \quad (4.18)$$

Si  $k = 1$ , entonces la distribución gamma resulta ser idéntica a la distribución exponencial; mientras que si  $k$  es un entero positivo, la distribución gamma coincide con la distribución de Erlang. Es conveniente notar que, a medida que  $k$  incrementa, la distribución gamma tiende, en forma asintótica, a una distribución normal.

Para generar valores de variable aleatoria con distribución gamma y con un valor esperado y varianza dados, se pueden emplear las siguientes fórmulas a fin de determinar los parámetros de  $f(x)$  en la ecuación (4.16):

$$\alpha = \frac{EX}{VX} \quad (4.19)$$

$$k = \frac{(EX)^2}{VX} \quad (4.20)$$

Debido a que para una distribución gamma no se puede formular explícitamente una función de distribución acumulativa, se debe considerar un método alternativo para generar valores de variable aleatoria con distribución gamma. En relación a tales valores que satisfacen la distribución de Erlang, éstos se pueden generar con sólo reproducir el proceso aleatorio sobre el cual se basa la distribución de Erlang. Para lograr este resultado se debe tomar la suma de los  $k$  valores de variable aleatoria con distribución exponencial  $x_1, x_2, \dots, x_k$ , cuyo valor esperado es el mismo e igual a  $1/\alpha$ . En consecuencia, el valor de la variable aleatoria  $x$  se puede expresar como

$$x = \sum_{i=1}^k x_i = -\frac{1}{\alpha} \sum_{i=1}^k \log r_i \quad (4.21)$$

#### 4.1.4. Distribución Normal

La más conocida y más ampliamente utilizada distribución de probabilidad es sin duda la distribución normal y su popularidad se debe cuando menos a dos razones que presentan sus propiedades generales. “Las pruebas matemáticas nos señalan, que *bajo ciertas condiciones de calidad*, resulta justificado que esperemos una distribución normal mientras que la experiencia estadística muestre que, de hecho, muy a menudo las distribuciones se aproximan a la normal”.

La distribución normal basa su utilidad en el teorema del límite central. Este teorema postula que, la distribución de probabilidad de la suma de  $N$  valores de variable aleatoria  $x_i$  independientes pero idénticamente distribuidos, con medias respectivas  $\mu_i$  y varianzas  $\sigma_i^2$ , se aproxima asintóticamente a una distribución normal, a medida que  $N$  se hace muy grande, y que dicha distribución tiene como media y varianza respectivamente, a

$$\mu = \sum_{i=1}^N \mu_i \quad (4.22)$$

$$\sigma^2 = \sum_{i=1}^N \sigma_i^2 \quad (4.23)$$

En consecuencia, el teorema del límite central permite el empleo de distribuciones normales para representar medidas globales operadas sobre los efectos de causas (errores) aditivas distribuidas en forma independiente, sin importar la distribución de probabilidad a que obedezcan las mediciones de causas individuales. El carácter que se atribuye a esta forma de interpretación del teorema del límite central resulta de particular importancia, ya que de esta manera se provee una justificación matemática para manipular la evidencia empírica, que tan frecuentemente aparece en los datos distribuidos en forma aproximadamente normal, obtenidos en una gran mayoría de problemas de investigación.

Otro rasgo valiosamente práctico de la distribución normal, es su utilidad para aproximar distribuciones de Poisson y binomiales para mencionar sólo dos entre muchas. A partir de la distribución normal, se pueden derivar otras muchas de las distribuciones existentes que juegan un papel muy importante en la estadística moderna, por ejemplo la Ji cuadrada, la  $t$ , y la distribución  $F$ , las cuales se originan a partir de consideraciones hechas sobre la distribución de probabilidad de la suma de los cuadrados de un número específico de valores de variables aleatoria con una distribución normal estándar.

Si la variable aleatoria  $X$  tiene una función de densidad  $f(x)$  dada como

$$f(x) = \frac{1}{\sigma_x \sqrt{2\pi}} e^{-1/2 \left( \frac{x - \mu_x}{\sigma_x} \right)^2}, \quad -\infty < x < \infty \quad (4.24)$$

con  $\sigma_x$  positiva, entonces se dice que  $X$  tiene una distribución normal o Gaussiana, con parámetros  $\mu_x$  y  $\sigma_x$ .




Figura 6: Distribución Normal.

En la Figura 6 se muestra la ya conocida gráfica con su forma de campana, de la función de densidad normal. Si los parámetros de la distribución normal tienen los valores  $\mu_x = 0$  y  $\sigma_x = 1$ , la función de distribución recibirá el nombre de *distribución normal estándar*, con función de densidad

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-1/2z^2} \quad -\infty < z < \infty \quad (4.25)$$

Cualquier distribución normal se puede convertir a la forma estándar, mediante la siguiente substitución:

$$z = \frac{x - \mu_x}{\sigma_x} \quad (4.26)$$

La función de distribución acumulativa  $F(x)$  o  $F(z)$  no existe en forma explícita; sin embargo esta última se encuentra totalmente tabulada en cualquier libro sobre estadística. El valor esperado y la varianza de la distribución normal no estándar están dados por:

$$EX = \mu_x \quad (4.27)$$

$$VX = \sigma_x^2 \quad (4.28)$$

Existen varios métodos para generar en una computadora, valores de variable aleatoria distribuidos en forma normal, de los cuales se podría decir que el más destacado es el llamado del límite central.

A fin de simular una distribución normal con media  $\mu_x$  y varianza  $\sigma_x^2$  dadas, se debe proponer la siguiente interpretación matemática del teorema del límite central. Si  $r^1, r^2, \dots, r^y$  representan variables aleatorias independientes, cada una de las cuales posee la misma distribución de probabilidad caracterizada por  $E(r_i) = \theta$  y  $Var(r_i) = \sigma^2$ , entonces

$$\lim_{N \rightarrow \infty} P \left[ a < \frac{\sum_{i=1}^N r_i - N\theta}{\sqrt{N} \sigma} < b \right] = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{1}{2}z^2} dz \quad (4.29)$$

donde

$$E \left( \sum_{i=1}^N r_i \right) = N\theta \quad (4.30)$$

$$Var \left( \sum_{i=1}^N r_i \right) = N\sigma^2 \quad (4.31)$$

$$z = \frac{\sum_{i=1}^N r_i - N\theta}{\sigma\sqrt{N}} \quad (4.32)$$

Tanto de la definición de la distribución normal estándar como de la Ecuación (4.26), se sigue que  $z$  es un valor de variable aleatoria con distribución normal estándar.

El procedimiento para simular valores normales utilizando computadoras requiere el uso de la suma de  $K$  valores de variable aleatoria distribuidos uniformemente; esto es, la suma de  $r_1, r_2, \dots, r_N$ , con cada  $r_i$  definida en el intervalo  $0 < r_i < 1$ . Aplicando la convención notacional de la forma matemática del teorema del límite central, así como los conocimientos previos de la distribución uniforme, encontramos que

$$\theta = \frac{a+b}{2} = \frac{0+1}{2} = \frac{1}{2} \quad (4.33)$$

$$\sigma = \frac{b-a}{\sqrt{12}} = \frac{1}{\sqrt{12}} \quad (4.34)$$

$$z = \frac{\sum_{i=1}^K r_i - K/2}{\sqrt{K/12}} \quad (4.35)$$

Pero, por definición,  $z$  es un valor de variable aleatoria con distribución normal estandar que se puede escribir en la forma sugerida por la Ecuación (4.26), donde  $x$  es un valor de variable aleatoria distribuido en forma normal que se va a simular, con media  $\mu_x$  y varianza  $\sigma_x^2$ . Igualando las Ecuaciones (4.35) y (4.26) obtendremos:

$$\frac{x - \mu_x}{\sigma_x} = \frac{\sum_{i=1}^K r_i - K/2}{\sqrt{K/12}} \quad (4.36)$$

y resolviendo para  $x$ , se tiene que

$$x = \sigma_x \left( \frac{12}{K} \right)^{1/2} \left( \sum_{i=1}^K r_i - \frac{K}{2} \right) + \mu_x \quad (4.37)$$

Por lo tanto, mediante la Ecuación (4.37) podemos proporcionar una formulación muy simple para generar valores de variable aleatoria normalmente distribuidos, cuya media sea igual a  $\mu_x$  y varianza  $\sigma_x^2$ . Para generar un solo valor de  $x$  (un valor de variable aleatoria con distribución normal) bastará con sumar  $K$  números aleatorios definidos en el intervalo de 0 a 1. Substituyendo el valor de esta suma en la Ecuación (4.37), así como también los valores de  $\mu_x$  y  $\sigma_x$  para la distribución deseada, encontraremos que se ha determinado un valor particular de  $x$ . Ciertamente, este procedimiento se puede repetir tantas veces como valores de variable aleatoria normalmente distribuidos se requieran.

El valor de  $K$  que debe aplicarse a las fórmulas usualmente se determina al establecer las condiciones de balance entre la eficiencia de cómputo y la precisión. Al considerar la convergencia asintótica implicada por el procedimiento del límite central, es deseable que  $K$  corresponda a un número muy grande. Considerando el tiempo que comprende la generación de  $K$  valores uniformes por cada valor de variable aleatoria normal, sería preferible que  $K$  estuviera asociada a un número muy chico. En la práctica de simulación se recomienda una  $K = 10$ , como el menor valor deseable. Sin embargo, con  $K = 12$  se logra una cierta ventaja computacional, ya que en la Ecuación (4.37) se puede evitar una multiplicación constante. No obstante, este valor de  $K$  trunca la distribución a los límites  $\pm 6$ , y además, se ha encontrado que no es confiable para valores de  $x$  mayores que tres de las desviaciones estándar, aunque pese a lo anterior, la experiencia muestra que este criterio conduce a programas de razonable rapidez. Con el fin de obtener mayor precisión se deben considerar valores mayores para  $K$  (del orden de  $K = 24$ ), de acuerdo con la llamada técnica de aproximación de Teichroew, aunque en estos casos la eficiencia del procedimiento del límite central resulta significativamente menor a la de otros criterios.

La aproximación de Teichroew mejora la precisión de las probabilidades de los eventos extremos, obtenidas con el procedimiento del límite central. Con  $K = 12$  deberemos calcular el valor de

$$y = \frac{\left( \sum_{i=1}^{12} r_i - 6 \right)}{4} \quad (4.38)$$

y el siguiente polinomio servirá para obtener el valor de la variable aleatoria  $z$  distribuida normalmente:

$$z = a_1 y + a_3 y^3 + a_5 y^5 + a_7 y^7 + a_9 y^9 \quad (4.39)$$



donde

$$a_1 = 3.949846138$$

$$a_3 = 0.252408784$$

$$a_5 = 0.076542912$$

$$a_7 = 0.008355968$$

$$a_9 = 0.029899776$$

A continuación, se presenta un breve resumen de otros dos procedimientos para generar valores de variable aleatorias distribuidas normalmente.

### El procedimiento directo

Sean  $r_1$  y  $r_2$  dos valores de variable aleatoria independientes distribuidos de modo uniforme y definidos en el intervalo  $(0, 1)$ , entonces:

$$x_1 = (-2\log_e r_1)^{1/2} \cos 2\pi r_2 \quad (4.40)$$

$$x_2 = (-2\log_e r_1)^{1/2} \sen 2\pi r_2 \quad (4.41)$$

serán dos valores de variable aleatoria obtenidos a partir de una distribución normal estándar. Con este método se logran resultados exactos y su velocidad de cómputo se puede comparar con la del método del límite central, sujeto a la eficiencia de ciertas subrutinas para funciones especiales.

### El procedimiento rápido

Se afirma que esta técnica es la mas rápida, aunque se le imputa que emplea varios cientos de ubicaciones de memoria para almacenar en la computadora ciertas constantes específicas. Las desviaciones aleatorias normales se calculan a partir de la mezcla de tres densidades:

$$f(x) = 0.9578g_1(x) + 0.0395g_2(x) + 0.0027g_3(x) \quad (4.42)$$

Los fundamentos racionales en los que se basa esta mezcla establecen que del 95 al 87 por ciento del tiempo sólo se usa  $g_1(x)$ , lo cual proporciona inmediatamente una variable normal con una tabla de longitud mínima. Las otras dos funciones son considerablemente más complicadas.

También pueden emplearse otros caminos, para generar valores de variable aleatoria normales, como el *método de rechazos* (Von Neumann) y el *método de Hastings*, aunque ninguno de estos métodos ofrece más simplicidad, precisión o rapidez, que los vistos previamente.

Las siguientes distribuciones se derivan de la distribución normal y por lo tanto, se pueden simular en forma indirecta por medio de ciertas funciones cuyos argumentos sean valores de variable aleatoria con distribución normal.

La distribución *Ji* cuadrada se obtiene mediante la suma de los cuadrados de los valores de variable aleatoria independientes, que obedecen a una distribución normal estándar. La variable *Ji* cuadrada se denota por

$$x = \chi_m^2 = \sum_{i=1}^m z_i^2 \quad (4.43)$$

donde  $z_i$  es una variable normal estándar y  $m$  representa los *grados de libertad*. La función de densidad  $\chi_m^2$  o  $x$  es una densidad gamma, con  $k = m/2$  y  $\sigma = 1/2$ .

En consecuencia,

$$f(x) = \frac{x^{\frac{m}{2}-1} e^{-\frac{x}{2}}}{2^{\frac{m}{2}} \left(\frac{m}{2} - 1\right)!} \quad (4.44)$$

y  $EX = m$  y  $VX = 2m$ .

Esta distribución queda completamente descrita una vez conocidos los grados de libertad y se pueden, por lo tanto, simular muy fácilmente si  $m$  resulta par. Cuando se trate de grados de libertad impares y  $m < 30$ , pueden utilizarse la Ecuación (4.43); mientras que si  $m > 30$  se podrá emplear el criterio de la aproximación normal para variables  $Ji$  cuadrada, basado en la conocida fórmula:

$$z = \sqrt{2\chi_m^2} - \sqrt{2m - 1} \quad (4.45)$$

Resolviendo para el valor  $Ji$  cuadrado  $\chi_m^2$ , obtenemos:

$$x = \chi_m^2 = \frac{(z + \sqrt{2m - 1})^2}{2} \quad (4.46)$$

La distribución  $t$  describe una variable aleatoria tal, que

$$t = \frac{z}{\sqrt{\chi_m^2/m}} \quad (4.47)$$

con una función de densidad

$$f(t) = \frac{\Gamma\left(\frac{m+1}{2}\right)}{\Gamma\left(\frac{m}{2}\right) \left[\pi m \left(1 + \frac{t^2}{m}\right)^{m+1}\right]^{1/2}} \quad (4.48)$$

La distribución acumulativa correspondiente a la distribución  $t$  se encuentra disponible tan sólo de forma tabular;  $EX = 0$  y  $VX = m/(m - 2)$ .

Para propósitos de simulación se puede usar la Ecuación (4.47) o sea, el cociente que se obtiene entre los valores de variable aleatoria con distribución normal estándar y los valores de variable aleatoria distribuidos en forma  $Ji$  cuadrada; en forma alternativa, es posible utilizar un valor de variable aleatoria distribuida en forma normal estándar, cuya varianza sea  $m/(m - 2)$ . Para  $m > 30$ , bastará con que se aplique el criterio directo de la aproximación normal.

La distribución  $F$  corresponde a la distribución de probabilidad de los cocientes que se obtienen entre las sumas correspondientes de los cuadrados de los valores de variable aleatoria con distribución normal. En otras palabras, se puede representar la variable  $F$  bajo la siguiente notación:

$$F_{m,n} = \frac{\chi_m^2/m}{\chi_n^2/n} \quad (4.49)$$

donde  $m$  y  $n$  representan los correspondientes grados de libertad de las sumas independientes, al igual que los valores  $Ji$  cuadrados.

A pesar de que tanto la función de densidad como la acumulativa de las variables  $F$  son bastante complicadas, sus momentos son relativamente simples, es decir,

$$EX = \frac{n}{n-2}, \quad n > 2 \quad (4.50)$$

$$VX = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}, \quad n > 4 \quad (4.51)$$

Finalmente, conviene tener en cuenta que los valores  $F$  se pueden simular mediante el uso de las Ecuaciones (4.49) y (4.43).

Por último, compartimos el código desarrollado en Python sobre el Método de la Transformación Inversa, el Método de Rechazo y el testeo de la generación de valores con una Distribución Normal mediante la generación de gráficas superpuestas que representen dichos valores generados por los métodos:

### Método de la Transformación Inversa

---

```

1 import numpy as np
2
3
4 # Generador de numeros uniformes
5 def dist_uniforme(cantidad=100):
6     return np.random.uniform(low=0.0, high=1.0, size=cantidad)
7
8
9 # Transformo un arreglo de numeros uniformes a una normal con el procedimiento
   directo
10 def transformar_inversa_normal(array):
11     resultado = []
12     for i in range(0, len(array), 2):
13         if i + 1 < len(array):
14             r1 = array[i]
15             r2 = array[i + 1]
16
17             z1 = np.sqrt(-2 * np.log(r1)) * np.cos(2 * np.pi * r2)
18             z2 = np.sqrt(-2 * np.log(r1)) * np.sin(2 * np.pi * r2)
19
20             resultado.append(z1)
21             resultado.append(z2)
22
23     return np.array(resultado)
24
25
26 def normal_parametros(valores_estandar, mu=0, sigma=1):
27     """
28     Adapta valores de una normal estandar a N(mu, sigma^2)
29     """
30     return mu + sigma * valores_estandar
31
32
33 # Generacion de muestras
34 mu = 0
35 sigma = 1
36 cantidad_numeros = 2000
37
38 arreglo_uniforme = dist_uniforme(cantidad_numeros)
39 arreglo_normal_inversa = transformar_inversa_normal(arreglo_uniforme)
40 arregloN_inversa_parametros = normal_parametros(arreglo_normal_inversa, mu, sigma)

```

---

Código 6: Implementación del Método de Transformación Inversa para generar muestras de una Distribución Normal  $N(\mu, \sigma^2)$  a partir de números pseudoaleatorios uniformes.

## Método de Rechazo

---

```
1 import numpy as np
2
3
4 # Generador de numeros uniformes
5 def dist_uniforme(cantidad=100):
6     return np.random.uniform(low=0.0, high=1.0, size=cantidad)
7
8
9 # Metodo de rechazo
10 def normal_rechazo(array_uniforme):
11     if len(array_uniforme) % 2 != 0:
12         array_uniforme = array_uniforme[:-1]
13
14     resultado = []
15     rechazos = 0
16     total_intentos = 0
17
18     # Rango para mapear [0,1] a [-a,a]
19     # Esto es necesario porque la distribucion normal tiene soporte en todo R (no
20     # solo en [0,1]).
21     a = 4.0
22
23     i = 0
24     while i < len(array_uniforme) - 1:
25         total_intentos += 1
26
27         u1 = array_uniforme[i]
28         x = -a + 2 * a * u1 # Mapear [0,1] a [-a,a]
29
30         # Segundo valor para el criterio de aceptacion
31         u2 = array_uniforme[i + 1]
32
33         # Funcion de densidad normalizada
34         fx_normalizada = np.exp(-(x**2) / 2)
35
36         # Criterio de aceptacion
37         if u2 <= fx_normalizada:
38             resultado.append(x)
39         else:
40             rechazos += 1
41
42         i += 2
43
44     tasa_aceptacion = len(resultado) / total_intentos if total_intentos > 0 else 0
45     print(f"Tasa de aceptacion: {tasa_aceptacion:.4f}")
46     print(f"Total de rechazos: {rechazos}")
47     print(f"Valores generados: {len(resultado)}")
48
49     return np.array(resultado)
50
51 def normal_parametros(valores_estandar, mu=0, sigma=1):
52     """
53     Adapta valores de una normal estandar a N(mu, sigma^2)
54     """
55     return mu + sigma * valores_estandar
56
57
58 # Generacion de muestras con el metodo de rechazo
59 mu = 0
60 sigma = 1
61 cantidad_numeros = 2000
```

```

62
63 arreglo_uniforme = dist_uniforme(cantidad_numeros)
64 arreglo_normal_rechazo = normal_rechazo(arreglo_uniforme)
65 arregloN_rechazos_parametros = normal_parametros(arreglo_normal_rechazo, mu, sigma
)

```

Código 7: Implementación del Método de Rechazo para generar muestras de una Distribución Normal estándar, utilizando un criterio de aceptación basado en la función de densidad normalizada y ajustando posteriormente los parámetros  $\mu$  y  $\sigma$ .

### Testeo de valores generados mediante gráficas

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4
5 arreglo_numpy = np.random.normal(mu, sigma, len(arregloN_rechazos_parametros))
6
7 # Graficos
8 plt.figure(figsize=(12, 8))
9
10 # Histograma Metodo de Rechazo
11 plt.hist(
12     arregloN_rechazos_parametros,
13     bins=30,
14     density=True,
15     alpha=0.6,
16     color="r",
17     label="Metodo de Rechazo",
18 )
19
20
21 # Histograma Transformada Inversa
22 plt.hist(
23     arregloN_inversa_parametros,
24     bins=30,
25     density=True,
26     alpha=0.6,
27     color="g",
28     label="Transformada Inversa",
29 )
30
31 # Histograma NumPy
32 plt.hist(
33     arreglo_numpy, bins=30, density=True, alpha=0.6, color="b", label="NumPy
normal"
34 )
35
36 x = np.linspace(-4, 4, 1000)
37 y = (1 / (sigma * np.sqrt(2 * np.pi))) * np.exp(-0.5 * ((x - mu) / sigma) ** 2)
38 plt.plot(x, y, "k-", lw=2, label="Funcion teorica")
39 plt.xlim(-4, 4)
40 plt.xlabel("Valor")
41 plt.ylabel("Densidad")
42 plt.title("Distribucion Normal Comparacion")
43 plt.legend()
44 plt.tight_layout()
45 plt.savefig("distribuciones_normales.png")
46 plt.show()

```

Código 8: Código para el testeo de los valores generados mediante la utilización de gráficas comparativas, mostrando histogramas de las muestras generadas por el Método de la Transformación Inversa, el Método de Rechazo y la función incorporada de NumPy, junto con la función de densidad teórica de la Distribución Normal.

## Gráficas superpuestas generadas

Estas son las gráficas superpuestas generadas por el código anterior:




Figura 7: Comparación de distribuciones normales generadas por diferentes métodos.

En la Figura 7 se muestra una comparación entre diferentes métodos para generar números pseudoaleatorios con distribución normal  $N(\mu = 0, \sigma = 1)$ . El histograma representa tres conjuntos de datos superpuestos: valores generados mediante el método de rechazo (en rojo), valores obtenidos por el método de la transformación inversa (en verde) y valores producidos directamente por la función `NumPy.random.normal()` (en azul). Adicionalmente, se grafica la función de densidad de probabilidad teórica de la distribución normal estándar (línea negra continua).

Se puede observar que los tres métodos generan distribuciones que se aproximan satisfactoriamente a la curva teórica. El método de la transformación inversa muestra una correspondencia particularmente precisa con la distribución normal teórica, evidenciando su eficiencia para generar valores normalmente distribuidos a partir de números uniformes. Por su parte, el método de rechazo presenta algunas pequeñas variaciones en ciertas regiones del histograma, lo cual es característico de este método debido a su naturaleza de aceptación-rechazo de valores candidatos. Finalmente, la implementación de NumPy proporciona resultados muy consistentes con la teoría, validando así la correcta implementación de los algoritmos.

Esta comparación permite visualizar la efectividad de los métodos implementados para la generación de variables aleatorias con distribución normal estándar a partir de valores uniformes, confirmando que tanto el método de la transformación inversa como el método de rechazo son alternativas viables a las funciones especializadas de bibliotecas como NumPy.

## 4.2. Distribuciones Discretas

Se encuentra definido un número muy significativo de distribuciones de probabilidad para variables aleatorias que solamente toman valores discretos, esto es, enteros no negativos. La distribución acumulativa de probabilidad para una variable aleatoria discreta  $X$  se define:

$$F(x) = P(X \leq x) = \sum_{X=0}^x f(x) \quad (4.52)$$

donde  $f(x)$  es la frecuencia o función de probabilidad de  $X$ , definida por valores enteros  $x$  tales que:

$$f(x) = P(X = x) \quad (4.53)$$

Las distribuciones discretas de probabilidad son muy útiles cuando se las emplea como modelos estocásticos para ciertos procesos de conteo, ya sea sobre muestras finitas o no finitas, donde la presencia o ausencia de un atributo dicotómico está gobernada por el azar. Desde un punto de vista empírico las distribuciones discretas pueden también ocurrir como resultado de redondear medidas continuas sobre una escala discreta. Sin embargo, estrictamente hablando, las distribuciones discretas de probabilidad resultan ser los modelos más apropiados para fenómenos aleatorios cuando los valores de las variables aleatorias se pueden determinar por medio de procesos de conteo.

Entre las distribuciones de probabilidad discretas más conocidas que se utilizan en el modelado estadístico se incluyen:

- Distribución Pascal (Binomial Negativa)
- Distribución Binomial
- Distribución Hipergeométrica
- Distribución Poisson
- Distribución Empírica Discreta

#### 4.2.1. Distribución Pascal (Binomial Negativa)

Cuando los procesos de ensayos de Bernoulli, tal como se han descrito en la sección anterior, se repiten hasta lograr que ocurran  $k$  éxitos ( $k > 1$ ), la variable aleatoria que caracteriza al número de fallas tendrá una distribución binomial negativa. Por consiguiente, los valores de variables aleatorias con distribución binomial negativa coinciden esencialmente con la suma de  $k$  valores de variable aleatoria con distribución geométrica; en este caso,  $k$  es un número entero y la distribución recibe el nombre de distribución de Pascal. En consecuencia, la distribución geométrica constituye un caso particular de la distribución de Pascal, especificada para  $k$  igual a uno.

La función de distribución de probabilidad para una distribución binomial negativa está dada por

$$f(x) = \binom{k+x-1}{x} p^k q^x \quad x = 0, 1, 2, \dots \quad (4.54)$$

donde  $k$  es el número total de éxitos en una sucesión de  $k+x$  ensayos, con  $x$  el número de fallas que ocurren antes de obtener  $k$  éxitos.

El valor esperado y la varianza de  $X$  se representa con:

$$EX = \frac{kq}{p} \quad (4.55)$$

$$VX = \frac{kq}{p^2} \quad (4.56)$$

Se debe hacer notar que tanto la distribución geométrica como la binomial negativa se caracterizan por una sobredispersión, esto es,  $VX > EX$ .

Para una media y una varianza dadas, se pueden determinar los parámetros  $p$  y  $k$  de la siguiente manera

$$p = \frac{EX}{VX} \quad (4.57)$$

$$k = \frac{(EX)^2}{VX - EX} \quad (4.58)$$

Sin embargo, puede suceder que el proceso de simulación se complique considerablemente cuando resulte que en la Ecuación (4.58) el valor que se obtenga al efectuar el cómputo de  $k$  no sea un entero.

Cuando  $k$  es un entero, los valores de la variable aleatoria con distribución de Pascal se pueden generar con sólo considerar la suma de  $k$  valores con distribución geométrica. En consecuencia:

$$x = \frac{\sum_{i=1}^k \log r_i}{\log q} \quad (4.59)$$

viene a ser un valor de variable aleatoria con distribución de Pascal, una vez que su magnitud se redondea con respecto al menor entero más próximo al valor calculado.

Cuando  $k$  no resulte ser un entero, deberemos confinarnos a los métodos de aproximación para generar valores de variable aleatoria con distribución binomial negativa. Uno de tales métodos implica la generación de una mezcla de valores de variable aleatoria con dos valores enteros, diferentes para  $k$ . Por ejemplo, si  $k$  es igual a 3.60 podríamos generar una mezcla de valores de variable aleatoria con distribución de Pascal:  $k$  igual a 3 en un caso y con  $k$  igual a 4 en otro; aunque tomando siempre en cuenta que el valor esperado de  $k$  es igual a 3.60. Otra alternativa es la que considera la generación de valores de variable aleatoria con distribución de Poisson, cuyo único parámetro se ajuste a una distribución gamma de parámetros  $k$  y  $\alpha$ . Los valores binomiales negativos que se generan es este último criterio tendrán los parámetros  $k$  y  $p$ , en donde

$$p = \frac{\alpha}{1 + \alpha} \quad (4.60)$$

Los valores de variable aleatoria con distribución de Pascal también se pueden definir como el número total de ensayos, de tal suerte que ocurren  $x$  fallas antes de que ocurran  $k$  éxitos. En este caso, el valor de la variable aleatoria ajustado a la distribución de Pascal estará dado por  $k + x$ . De acuerdo con esta proposición, la media de estos valores está definida por

$$F(k + x) = \frac{kq}{p} + k = \frac{k}{p} \quad (4.61)$$

#### 4.2.2. Distribución Binomial

Las variables aleatorias definidas por el número de eventos exitosos en una sucesión de  $n$  ensayos independientes de Bernoulli, para los cuales la probabilidad de éxito es  $p$  en cada ensayo, siguen una distribución binomial. Este modelo estocástico también se puede aplicar al proceso de muestreo aleatorio con reemplazo, cuando los elementos muestreados tienen sólo dos tipos de atributos (por ejemplo si y no, respuestas como defectuoso o aceptable). El diseño de una muestra aleatoria de  $n$  elementos es análoga a  $n$  ensayos independientes de Bernoulli, en los que  $x$  es un valor binomial que está denotando al número de elementos de una muestra de tamaño  $n$  con atributos idénticos. Es ésta la analogía que sitúa la distribución binomial como uno de los modelos más importantes en las áreas del muestreo estadístico y del control de calidad.

La distribución binomial proporciona la probabilidad de que un evento o acontecimiento tenga lugar  $x$  veces en un conjunto de  $n$  ensayos, donde la probabilidad de éxito está dada por  $p$ . La función de probabilidad para la distribución binomial se puede expresar de la siguiente manera:

$$f(x) = \binom{n}{x} p^x q^{n-x} \quad (4.62)$$

donde  $x$  se toma como un entero definido en el intervalo finito  $0, 1, 2, \dots, n$ , y al que se le asocia el valor  $q = (1 - p)$ . El valor esperado y la varianza de la variable binomial  $X$  son

$$EX = np \quad (4.63)$$

$$VX = npq \quad (4.64)$$



La segunda expresión implica que la varianza de las variables binomiales siempre tiene un valor menor al de la media. Aún más, se puede notar cómo se define en la ecuación (4.62) la distribución  $(n - x)$  como un valor esperado correspondiente de  $nq$ .

Cuando se conocen la media y la varianza, resulta inmediata la determinación de  $p$  y de  $n$ , las cuales pueden calcularse como sigue:

$$p = \frac{EX - VX}{EX} \quad (4.65)$$

$$n = \frac{(EX)^2}{EX - VX} \quad (4.66)$$

La distribución normal proporciona, cuando  $n$  es muy grande, una buena aproximación para la distribución binomial. Puesto que con la distribución normal resulta posible manipular valores negativos, a fin de hacer un buen uso de tal distribución la probabilidad de registrar observaciones negativas deberá ser despreciablemente pequeña. En la práctica esto significa que el valor esperado deberá ser por lo menos tres veces mayor que la desviación estándar, o sea

$$np \geq 3 (npq)^{1/2} \quad (4.67)$$

lo cual implica que  $n \geq 9 q/p$ .

Los valores de variable aleatoria con distribución binomial se pueden generar de muy diversos modos, aunque uno de los métodos más simples, que en el caso de que el valor de  $n$  sea moderado resulta uno de los métodos más eficiente, es el basado en la reproducción de ensayos de Bernoulli, siguiendo el método de rechazos. Este método empieza con valores conocidos de  $p$  y de  $n$  y consiste en generar  $n$  números aleatorios después de fijar  $x_0$  igual a cero. Para cada número aleatorio  $r_i$  ( $1 \leq i \leq n$ ) se efectúa una prueba y la variable  $x_i$  se incrementa de acuerdo con el siguiente criterio:

$$x_i = x_{i-1} + 1 \quad \text{si } r_i \leq p \quad (4.68)$$

$$x_i = x_{i-1} \quad \text{si } r_i > p \quad (4.69)$$

Después de haberse generado  $n$  números aleatorios, el valor de  $x_n$  será igual al valor de la variable aleatoria con distribución binomial  $x$ . Este procedimiento se puede repetir tantas veces como valores binomiales se requieran.

Un segundo método para generar valores binomiales es el que se basa en las sumas aleatorias de valores de variables aleatorias con distribución geométrica, con lo cual se obtiene el número de éxitos de  $n$  ensayos. En el caso de que  $p$  sea pequeño, este método puede ser mucho más rápido.

A continuación, compartimos las gráficas generadas durante el testeo de la generación de números pseudoaleatorios con una Distribución Binomial:




Figura 8: Comparación de distribuciones binomiales generadas mediante diferentes métodos.

En la Figura 8 se muestra una comparación entre diferentes métodos para generar números pseudoaleatorios con distribución binomial. La gráfica izquierda presenta la distribución binomial  $B(n = 20, p = 0.3)$  generada directamente mediante la función `NumPy.random.binomial()`, donde el histograma con barras azules representa las muestras obtenidas a partir de 1000 simulaciones, mientras que la línea roja continua corresponde a la función de densidad de masa (PMF) teórica. En la gráfica derecha se visualiza la distribución binomial  $B(n = 10, p = 0.6)$  generada mediante el método de rechazo, con un histograma de barras celestes superpuesto a la PMF teórica también representada en color rojo.

Se puede observar que ambos métodos producen distribuciones que se ajustan de manera satisfactoria a sus respectivas curvas teóricas. La distribución obtenida directamente mediante la función de `NumPy` muestra una correspondencia muy precisa con la PMF teórica, con una media muestral cercana al valor esperado de  $np = 6.0$  y una varianza aproximada a  $np(1 - p) = 4.2$ . Por su parte, el método de rechazo también genera una distribución que se aproxima adecuadamente a la teórica para los parámetros  $n = 10$  y  $p = 0.6$ , con ligeras variaciones en algunas frecuencias específicas, propias de la naturaleza probabilística del algoritmo de aceptación-rechazo, que en este caso presenta una eficiencia cercana al  $1/M$ .

Además, realizamos el Test de Chi-Cuadrado sobre ambos métodos de generación de números pseudoaleatorios con Distribución Binomial, obteniendo los siguientes resultados:

---

```

1 --- Testeo de la Distribucion Binomial (NumPy) ---
2 Chi-Cuadrado Test B(20, 0.3): Estadistico = 18.8039, p-valor = 0.0934
3 La muestra original proviene de una distribucion binomial (Chi-cuadrado no rechaza
  la Hipotesis Nula (H0)).
4
5 --- Testeo de la Distribucion Binomial (Metodo de Rechazo) ---
6 Chi-Cuadrado Test B(10, 0.6): Estadistico = 5.7798, p-valor = 0.6719
7 La muestra generada por el metodo de rechazo proviene de una distribucion binomial (
  Chi-cuadrado no rechaza la Hipotesis Nula (H0)).

```

---

Los resultados del Test de Chi-Cuadrado aplicado a ambas distribuciones confirman estadísticamente que las muestras generadas siguen las distribuciones binomiales teóricas correspondientes. Para la distribución original  $B(20, 0.3)$  se obtuvo un estadístico de 18.8039 con un p-valor de 0.0934, mientras que para la distribución generada mediante el método de rechazo  $B(10, 0.6)$ , el estadístico fue 5.7798 con un p-valor de 0.6719. En ambos casos, los p-valores superan el nivel de significancia de 0.05, lo que no permite rechazar la hipótesis nula de que los datos provienen de las distribuciones binomiales especificadas. Esta comparación valida la efectividad del método de rechazo como alternativa viable para generar variables aleatorias con distribución binomial cuando no se dispone de funciones especializadas como las proporcionadas por bibliotecas matemáticas estándar.

### 4.2.3. Distribución Hipergeométrica

Considérese una población que consta de  $N$  elementos tales que cada uno de ellos pertenece a la clase I o a la II. Denotemos por  $N_p$  al número de elementos que pertenecen a la clase I y por  $N_q$  al número de elementos que son miembros de la clase II, donde  $p + q = 1$ . Si en una población de  $N$  elementos se toma una muestra aleatoria que conste de  $n$  elementos ( $n < N$ ) *sinquetengalugaralgunreemplazo*, entonces el número de elementos  $x$  de la clase I en la muestra de  $n$  elementos, tendrá una distribución de probabilidad hipergeométrica. En las áreas de control de calidad y en la de control de producción, con mayor frecuencia se encuentran las aplicaciones de la distribución hipergeométrica.

La distribución hipergeométrica está escrita por la siguiente función de probabilidad:

$$f(x) = \frac{\binom{N_p}{x} \binom{N_q}{n-x}}{\binom{N}{n}} \quad (4.70)$$

donde

- $0 \leq x \leq N_p$
- $0 \leq n - x \leq N_q$
- $x, n$  y  $N$  son enteros.

El valor esperado y la varianza se caracterizan como sigue:

$$EX = np \quad (4.71)$$

$$VX = npq \left( \frac{N-n}{N-1} \right) \quad (4.72)$$

La generación de valores hipergeométricos involucra substancialmente, la simulación de experimentos de muestreo **sin reemplazo**. En otras palabras, bastará sencillamente con que alteremos el método de ensayos de Bernoulli para generar valores binomiales, con objeto que  $N$  y  $p$  varíen de forma dependiente respecto al número total de elementos que previamente se han obtenido entre la población y el número de elementos de la clase I que se han extraído. A medida que se extrae un elemento de una muestra de  $n$  elementos, se reduce el valor de  $N = N_0$  de acuerdo con la fórmula:

$$N_i = N_{i-1} - 1 \quad i = 1, 2, \dots, n \quad (4.73)$$

De manera similar, el valor de  $p = p_0$  se transforma según

$$p_i = \frac{N_{i-1} p_{i-1} - S}{N_{i-1} - 1} \quad i = 1, 2, \dots, n \quad (4.74)$$

a medida que se saca el  $i$ -ésimo elemento de la muestra de  $n$  elementos. Donde  $S = 1$  cuando el elemento de muestra ( $i - 1$ ) pertenece a la clase II. Ciertamente, los valores iniciales de  $N_0$  y  $p_0$  corresponden: a  $N$  el tamaño inicial de la población y a  $p$  la proporción de la población total que consta de elementos de clase I.

#### 4.2.4. Distribución Poisson

Si tomamos una serie de  $N$  ensayos independientes de Bernoulli, en cada uno de los cuales que se tenga una probabilidad de  $p$  muy pequeña relativa a la ocurrencia de un cierto evento, a medida que  $n$  tiende al infinito, la probabilidad de  $x$  ocurrencias está dada por la distribución de Poisson

$$f(x) = e^{-\lambda} \frac{\lambda^x}{x!} \quad \lambda > 0 \quad (4.75)$$

siempre y cuando permitamos que  $p$  se aproxime a cero de manera que se satisfaga la relación  $\lambda = np$  consistentemente. De la discusión previa se sabe que  $np$  es el valor esperado de la distribución binomial y se puede demostrar que  $\lambda$  es el valor esperado para la distribución de Poisson. De hecho, tanto el valor esperado como la varianza de la distribución de Poisson coinciden en el valor  $\lambda$ . También se puede demostrar que si  $x$  es una variable de Poisson con parámetro  $\lambda$ , entonces para valores muy grandes de  $\lambda$  ( $\lambda > 10$ ), se puede aproximar la distribución de  $x$ .

Los eventos que se distribuyen en forma poissoniana ocurren frecuentemente en la naturaleza. Esta distribución es particularmente útil cuando se trata con problemas en los que se da la ocurrencia de eventos aislados sobre un intervalo continuo de tiempo, o bien cuando resulta posible prescribir el número de veces que ocurre un evento aunque no el número de veces que no ocurre.

Para simular una distribución de Poisson con parámetro  $\lambda$ , se puede servir ventajosamente de la relación conocida entre las distribuciones exponenciales y de Poisson. Se puede justificar que si:

1. el número total de eventos que ocurren durante un intervalo de tiempo dado es independiente del número de eventos que ya han ocurrido previamente al inicio del intervalo
2. la probabilidad de que un evento ocurra en el intervalo de  $t$  a  $t + \Delta t$  es aproximadamente  $\lambda \Delta t$  para todos los valores de  $t$

Entonces:

1. la función de densidad del intervalo  $t$  entre las ocurrencias de eventos consecutivos es  $f(t) = \lambda e^{-\lambda t}$ .

2. la probabilidad de que ocurran  $x$  eventos durante el tiempo  $t$  es

$$f(x) = e^{-\lambda t} \frac{(\lambda t)^x}{x!} \quad (4.76)$$

para toda  $x$  y toda  $t$ .

Considere un horizonte de tiempos que se inicia en el origen 0 como punto de referencia y que se ha dividido en intervalos unitarios, como se ilustra en la siguiente figura.




Figura 9: Eventos distribuidos en forma poissoniana, sobre una escala de tiempo

Suponga también que los eventos ocurren a lo largo del mencionado horizonte y que se denotan por el símbolo  $(\Lambda)$ . Se supondrá que el intervalo  $t$  entre eventos obedece a una distribución exponencial cuyo valor esperado es igual a  $1/\lambda$ . Con estos antecedentes se implica que el número de eventos  $x$  que ocurren durante un tiempo unitario seguirán una distribución de Poisson cuyo valor esperado estará dada por  $\lambda$ . Un método para generar valores de variable aleatoria con distribución de Poisson debe considerar la generación de intervalos  $t_1, t_2, t_3, \dots$ , distribuidos en forma exponencial con un valor esperado igual a 1. Una vez generados estos valores aleatorios, se acumulan hasta que su suma exceda al valor de  $\lambda$ .

En términos matemáticos el valor poissoniano de  $x$  se determina haciendo uso de la siguiente desigualdad:

$$\sum_{i=0}^x t_i \leq \lambda < \sum_{i=0}^{x+1} t_i \quad (x = 0, 1, 2, \dots) \quad (4.77)$$

donde los valores de la variable aleatoria  $t_i$  se generan por medio de la fórmula

$$t_i = -\log r_i \quad (4.78)$$

con una media unitaria.

A continuación, compartimos las gráficas superpuestas generadas durante el testeo de la generación de números pseudoaleatorios con una Distribución Poisson:




Figura 10: Comparación de distribuciones Poisson generadas mediante diferentes métodos.

En la Figura 10 se muestra una comparación entre diferentes métodos para generar números pseudoaleatorios con distribución de Poisson ( $\lambda = 4$ ). El histograma representa dos conjuntos de datos superpuestos: valores generados mediante el método de rechazo (en azul) y valores producidos directamente por la función `NumPy.random.poisson()` (en verde). Adicionalmente, se grafica la función de masa de probabilidad teórica de la distribución de Poisson con parámetro  $\lambda = 4$  (línea negra continua).

Se puede observar diferencias notables entre ambos métodos en su aproximación a la curva teórica. La implementación de NumPy (verde) muestra una mayor concentración alrededor del valor esperado  $\lambda = 4$ , con picos pronunciados en los valores 3 y 4, ajustándose con mayor precisión a la función teórica. Por su parte, el método de rechazo (azul) presenta una distribución más uniforme y aplanada, con frecuencias similares para los valores entre 2 y 6, lo que sugiere que este método tiende a subestimar la probabilidad en el centro de la distribución y sobreestimar las probabilidades en las colas.

En el histograma se distingue claramente la diferencia en la forma de ambas distribuciones: mientras que los datos obtenidos por NumPy (verde) exhiben un pico definido alrededor de  $\lambda = 4$  que coincide con la curva teórica, los datos generados mediante el método de rechazo (azul) muestran una distribución más rectangular entre los valores 2 y 6, con frecuencias relativamente similares en este rango. Es particularmente notable la diferencia en las alturas máximas: el método de NumPy alcanza probabilidades cercanas al 0.20 para los valores 3-4, mientras que el método de rechazo mantiene probabilidades aproximadamente constantes de 0.12 en un rango más amplio.

La discrepancia observada podría atribuirse a limitaciones en la implementación del método de rechazo, específicamente en la elección del factor de escalado  $c = 1.5$  y en la distribución propuesta (uniforme discreta). El valor de  $c$  podría no ser óptimo para toda la gama de valores posibles, afectando la eficiencia de aceptación en diferentes regiones del espacio muestral.

Esta comparación permite visualizar las limitaciones del método de rechazo implementado para la generación de variables aleatorias con distribución de Poisson. Si bien el método logra producir valores dentro del rango esperado, la aproximación a la distribución teórica es significativamente menos precisa que la implementación especializada de NumPy. Esto subraya la importancia de una correcta parametrización del algoritmo de rechazo, incluyendo la elección adecuada de la distribución propuesta y el factor de escalado, para garantizar una representación fiel de la distribución objetivo. En aplicaciones que requieran alta precisión estadística, sería recomendable utilizar implementaciones optimizadas como las proporcionadas por bibliotecas científicas, o refinar los parámetros del método de rechazo para mejorar su ajuste a la distribución teórica.

#### 4.2.5. Distribución Empírica Discreta

Ahora se tratará un método un tanto más general que puede emplearse para simular cualquiera de la siguientes distribuciones:

1. empírica
2. discreta
3. continua que pueda ser aproximada mediante una distribución discreta

El método que se propondrá en esta sección es uno que se utiliza siempre y cuando no se disponga de otra alternativa.

Sea  $X$  una variable aleatoria discreta con  $P(X = b_i) = p_i$ , tal como se presenta la variable aleatoria de la siguiente tabla:

| $b_i$    | $P(X = b_i) = p_i$ |
|----------|--------------------|
| $b_1$    | 0.273              |
| $b_2$    | 0.037              |
| $b_3$    | 0.195              |
| $b_4$    | 0.009              |
| $b_5$    | 0.124              |
| $b_6$    | 0.058              |
| $b_7$    | 0.062              |
| $b_8$    | 0.151              |
| $b_9$    | 0.047              |
| $b_{10}$ | 0.044              |

En consecuencia, resulta evidente que un método para generar  $x$  en una computadora es aquel que genera un valor de variable aleatoria  $r$  sujeto a una dsitribución uniforme, en el intervalo  $(0, 1)$  y un conjunto de valores  $x = b_i$  siempre que se satisfaga

$$p_1 + \dots + p_{i-1} < r \leq p_1 + \dots + p_i \quad (4.79)$$

Pese a que se han desarrollado un buen número de técnicas de búsqueda basadas en este método, en su gran mayoría requieren programas relativamente complejos que a su vez emplean un tiempo de computación excesivo.

Uno de los procediminetos más rápidos para generar valores de variable aleatoria discretos es el desarrollado por G. Marsaglia, quien presupone la disponibilidad de una computadora decimal cuyos bloques o palabras de memoria pueden referirse mediante números. Esta última característica, en realidad, constituye una propiedad de la gran mayoría de las computadoras actuales. En el procedimiento se mencionan los números 273  $b_1$ , 32  $b_2$ , 195  $b_3$ , ..., 44  $b_{10}$  y los que pertenecen a cada una de estas clases respectivas, en las ubicaciones de memoria desde la 0 a la 999. Entonces, si por ejemplo  $r = d_1 d_2 d_3 d_4$  es un número aleatorio uniforme de cuatro dígitos, generado por la computadora, el núemro en la localidad  $d_1 d_2 d_3$  será el valor de  $x$ .

Conviene tener en cuenta que si bien este método es extremadamente rápido, también requiere por lo menos una memoria de 1000 palabras. Existe otro método desarrollado también por Marsaglia que en forma alternativa utiliza mucho menos capacidad de memoria, aunque incrementa ligeramente el tiempo de computación.

A continuación, compartimos las gráficas generadas durante el testeo de la generación de números pseudoaleatorios con una Distribución Empírica Discreta:




Figura 11: Comparación de distribuciones empíricas discretas generadas mediante diferentes métodos.

En la Figura 11 se muestra una comparación entre diferentes métodos para generar números pseudoaleatorios que siguen una distribución empírica discreta definida por los valores  $\{1, 2, 3, 4, 5\}$  con probabilidades  $\{0.1, 0.2, 0.3, 0.2, 0.2\}$  respectivamente. La figura está dividida en dos gráficas: la de la izquierda (en color rojo) muestra los resultados del método de rechazo implementado manualmente, mientras que la gráfica de la derecha (en color celeste) presenta los resultados obtenidos mediante la función especializada *rv\_discrete* de la biblioteca *SciPy*. En ambos casos, se superponen líneas verticales negras que representan la distribución teórica de probabilidad.

Se puede observar que ambos métodos logran generar muestras que aproximan la distribución teórica, aunque con pequeñas diferencias perceptibles. Por ejemplo, en el valor 3, el método de rechazo se desvía más de la distribución teórica esperada, mientras que lo realizado con la librería *SciPy* se ajusta casi a la perfección.

El método de rechazo implementado utiliza un enfoque basado en la técnica estándar de aceptación-rechazo, donde se genera un índice aleatorio para seleccionar un candidato de entre los valores posibles, y luego se acepta con una probabilidad proporcional a su probabilidad teórica dividida por la probabilidad máxima. La anomalía observada en el valor 3 podría atribuirse a fluctuaciones estadísticas inherentes al proceso de muestreo o a sutilezas en la implementación del algoritmo de rechazo, como el uso de números aleatorios uniformes discretos para la selección inicial del candidato.

Esta comparación ilustra la efectividad de las implementaciones especializadas de bibliotecas como SciPy para generar muestras que se ajusten fielmente a distribuciones discretas arbitrarias. Al mismo tiempo, evidencia que los métodos de rechazo, aunque conceptualmente simples y flexibles, pueden requerir ajustes adicionales o un mayor tamaño muestral para lograr una representación precisa de la distribución objetivo, especialmente cuando se trata de distribuciones empíricas con valores de probabilidad no uniformes.

Todo lo desarrollado en las Secciones 2, 3 y 4 fue extraído del material elaborado por Thomas Naylor (Naylor, 1982).

## 5. Metodología de Trabajo

En este trabajo, desarrollamos un conjunto de scripts en Python con el objetivo de estudiar, implementar y comparar distintos métodos para la generación de números pseudoaleatorios que siguen diversas distribuciones de probabilidad. Con ese propósito, implementamos varios algoritmos de generación para cada distribución, realizamos tests estadísticos para validar la calidad de las muestras generadas y creamos visualizaciones gráficas que permiten comparar de forma intuitiva los resultados obtenidos con las distribuciones teóricas esperadas. El código fue organizado de manera modular, con archivos independientes para cada distribución, lo que favorece su claridad, reutilización y mantenimiento.

Algunos de los scripts mencionados se encuentran exhibidos durante el desarrollo de la Sección 4 de este informe.

### 5.1. Implementación de los métodos de generación

Se implementaron principalmente dos técnicas para la generación de variables aleatorias con distribuciones específicas:

- **Método de la transformación inversa:** Basado en la transformación de variables aleatorias uniformes mediante la función inversa de la distribución acumulada  $F^{-1}(u)$ , donde  $u \sim U(0, 1)$ .
- **Método de rechazo:** Técnica que permite generar variables aleatorias de una distribución objetivo muestreando de una distribución propuesta más simple y aceptando o rechazando las muestras según un criterio probabilístico.

Para cada distribución de probabilidad estudiada, se desarrolló un script independiente que implementa ambos métodos de generación cuando era aplicable, además de incluir la generación mediante las funciones proporcionadas por las bibliotecas NumPy y SciPy como referencia para comparación.

### 5.2. Distribuciones implementadas

Se desarrollaron implementaciones para las siguientes distribuciones de probabilidad:

- **Distribución Uniforme:** Se implementó tanto el método de la transformación inversa como el método de rechazo, comparando con la función `np.random.uniform()`.
- **Distribución Exponencial:** Implementada mediante la transformación inversa  $-\ln(1 - u)/\lambda$  y el método de rechazo.
- **Distribución Gamma:** Generada mediante la suma de exponenciales para el caso entero (transformación inversa) y un método de rechazo específico.
- **Distribución Normal:** Se utilizó el método de la transformación inversa y el método de rechazo, comparándolos con `np.random.normal()`.

- **Distribución Pascal** (Binomial Negativa): Implementada con el método de rechazo, comparando con `np.random.negative_binomial()`.
- **Distribución Binomial**: Implementada usando el método de rechazo en comparación con `np.random.binomial()`.
- **Distribución Poisson**: Generada mediante el método de rechazo, comparando con `np.random.poisson()`.
- **Distribución Hipergeométrica**: Generada mediante el método de rechazo, en comparación con `np.random.hypergeometric()`.
- **Distribución Empírica Discreta**: Implementada mediante el método de rechazo y comparada con el enfoque de `SciPy.stats.rv_discrete`.

Cada script incluye la implementación de las funciones necesarias para generar las muestras, así como funciones para visualizar y validar los resultados obtenidos.

### 5.3. Visualización mediante histogramas comparativos

Para cada distribución implementada, se desarrollaron una o más funciones de visualización que permiten comparar gráficamente:

- El histograma de las muestras generadas mediante el método de transformada inversa.
- El histograma de las muestras generadas mediante el método de rechazo.
- El histograma de las muestras generadas utilizando las funciones de *NumPy/SciPy*.
- La función de densidad de probabilidad (o función de masa en el caso discreto) teórica.

Estos gráficos se generaron utilizando la biblioteca *matplotlib.pyplot* y se guardaron como archivos de imagen *.png* para su posterior análisis y, en ciertos casos, su inclusión en este informe. Por ejemplo, para la distribución normal, se generó un gráfico que compara los tres métodos con la curva teórica, permitiendo una evaluación visual de la calidad de las aproximaciones.

### 5.4. Tests estadísticos

Para evaluar rigurosamente la calidad estadística de las muestras generadas, se aplicaron diversos tests según la naturaleza de cada distribución:

- **Test Chi-cuadrado**: Utilizado principalmente para distribuciones discretas como la Binomial, permitiendo comparar las frecuencias observadas con las esperadas según la distribución teórica.
- **Test de Kolmogorov-Smirnov**: Aplicado especialmente a distribuciones continuas como la Uniforme, para verificar si las muestras generadas siguen la distribución esperada.
- **Comparación de estadísticos descriptivos**: En todos los casos se calculan y comparan la media y la varianza muestrales con sus valores teóricos esperados.

Los resultados de estos tests incluyen tanto los estadísticos de prueba como los p-valores correspondientes, lo que permite evaluar la calidad de los generadores implementados bajo un nivel de significancia típicamente fijado en  $\alpha = 0.05$ .



## 5.5. Estructura general del código

Cada script de distribución sigue una estructura común:

1. **Importación de bibliotecas:** *NumPy* para cálculos numéricos y funciones estadísticas, *Matplotlib* para visualización de gráficas y *SciPy.stats* para otras funciones estadísticas.
2. **Definición de parámetros:** Configuración de los parámetros específicos de cada distribución y el tamaño de la muestra.
3. **Implementación de los métodos de generación:** Funciones para generar muestras mediante el método de la transformación inversa, el método de rechazo y los métodos provistos por las bibliotecas mencionadas en el primer ítem.
4. **Generación de muestras:** Ejecución de los métodos implementados para obtener las muestras aleatorias.
5. **Tests estadísticos:** Aplicación de tests para validar la calidad de las muestras generadas.
6. **Visualización:** Funciones para crear gráficos comparativos.

Esta estructura modular facilita la lectura, comprensión y mantenimiento del código, además de permitir la extensión a nuevas distribuciones o métodos de generación.

## 5.6. Ejecución y resultados

La ejecución de cada script genera:

1. En algunos casos, salida por consola con estadísticos descriptivos (media, varianza) y resultados de los tests aplicados.
2. Exhibición en una ventana emergente de los gráficos comparativos y guardado de archivos de imagen con dichos gráficos.

Por ejemplo, para ejecutar el análisis de la distribución normal:

```
python Normal.py
```

Este comando genera tanto la salida por consola con las estadísticas relevantes como una ventana emergente y un archivo de imagen `distribuciones_normales.png` con las comparaciones gráficas.

## 5.7. Análisis de eficiencia

Para algunos métodos, especialmente en el caso del método de rechazo, se incluye el cálculo y reporte de medidas de eficiencia:

- **Tasa de aceptación:** Proporción de muestras aceptadas respecto al total de intentos.
- **Número de rechazos:** Cantidad de muestras rechazadas durante el proceso.

Estas métricas son particularmente importantes para evaluar la eficiencia computacional del método de rechazo en cada distribución, permitiendo comparar la eficacia relativa del método según los parámetros y la distribución objetivo.

## 5.8. Bibliotecas utilizadas

Las principales bibliotecas utilizadas en la implementación fueron:

- NumPy: Para cálculos numéricos eficientes y funciones de generación de números pseudoaleatorios de distintas distribuciones de probabilidad.
- matplotlib.pyplot: Para la generación gráficos comparativos.
- SciPy: Para acceder a funciones estadísticas avanzadas, distribuciones teóricas y tests estadísticos.

Este conjunto de herramientas permitió implementar, validar y visualizar de manera efectiva los distintos métodos de generación de números pseudoaleatorios para cada distribución de probabilidad analizada en este informe.

## 6. Conclusiones

A través del desarrollo de este trabajo teórico-práctico sobre la generación de números pseudoaleatorios con diferentes distribuciones de probabilidad, profundizamos en los fundamentos estadísticos y computacionales que permiten simular fenómenos aleatorios bajo diversos modelos probabilísticos, tanto continuos como discretos.

Durante la investigación, se abordaron múltiples distribuciones de probabilidad (uniforme, exponencial, gamma, normal, binomial, Poisson, entre otras), implementando algoritmos específicos para su simulación a partir de métodos generales como la transformación inversa y el método de rechazo. En cada caso, se buscó no solo generar muestras numéricas acordes a la teoría, sino también validar su ajuste a la distribución teórica mediante pruebas estadísticas (como el test de Kolmogorov-Smirnov y chi-cuadrado) y visualizaciones gráficas comparativas.

En la práctica, vimos que la implementación correcta de estos métodos es clave para lograr resultados consistentes. Algunos métodos son más eficientes que otros, y no todos funcionan igual de bien para todas las distribuciones. También quedó claro que elegir bien los parámetros —como la media, la varianza o los límites del intervalo— es fundamental para que los valores generados se ajusten realmente a la distribución deseada.

Todo este proceso nos ayudó a entender mejor cómo funcionan estas herramientas por dentro, y por qué es importante no quedarse solo con el resultado numérico, sino analizarlo con criterio. Además, haber comparado nuestras simulaciones con funciones ya integradas en librerías como NumPy y SciPy nos permitió ver de forma concreta las ventajas y limitaciones de los métodos manuales de la transformación inversa y de rechazo.

En definitiva, el trabajo permitió consolidar los conceptos teóricos mediante su aplicación práctica en casos concretos. La implementación de distintos métodos y la validación de sus resultados proporcionaron una comprensión más profunda del comportamiento de las distribuciones de probabilidad en contextos simulados, así como de las fortalezas y limitaciones de los enfoques utilizados.

## Referencias

Naylor, T. H. (1982). *Técnicas de simulación en computadoras*. Editorial Limusa-Wiley.